

Sumário

1.	Análise por Tipo de Fonte — Desafios no Pipeline RAG	3
1	.	
1	PDFs com Tabelas Complexas (SharePoint)	3
1	.	
2	PDFs Escaneados com OCR (SharePoint)	4
1	.	
3	Wiki Confluence com Links Internos e Macros	4
1	.	
4	Planilhas com Fórmulas Interdependentes	5
2.	Estimativa do Tamanho da Base em Tokens	6
3.	Análise do Orçamento de Contexto	7
3	.	
1	Decomposição da Janela de 128K Tokens	7
3	.	
2	Capacidade de Chunks por Query	7
3	.	
3	Impacto na Estratégia de Chunking e Retrieval	8
4.	Estratégia de Chunking e o Efeito Lost in the Middle	9
4	.	
1	O Problema do Lost in the Middle	9
4	.	
2	Estratégia de Chunking Recomendada	9
4	.	1
3	Tipos de Perguntas e Chunking Adequado	1
5.	Considerações Complementares e Informações Ausentes	12

1. Análise por Tipo de Fonte — Desafios no Pipeline RAG

SEÇÃO 1.1

1.1 PDFs com Tabelas Complexas (SharePoint)

Desafio no pipeline. Tabelas com 15 ou mais colunas — como as tabelas de frete — apresentam o problema fundamental de que o chunking ingênuo por janela de tokens quebra as tabelas ao meio, separando cabeçalhos de valores. Um chunk que contém apenas linhas de dados sem os cabeçalhos das colunas é semanticamente inútil: o modelo não consegue inferir que "R\$ 12,50" pertence à coluna "Frete por kg — Zona Sul — Prazo 48h". A extração nativa de PDF por bibliotecas como PyMuPDF ou pdfplumber frequentemente serializa tabelas como texto linearizado, destruindo a estrutura relacional entre colunas.

Impacto na qualidade. Perguntas do tipo "Qual o valor do frete para carga refrigerada acima de 500kg com destino à Zona Leste?" exigem que o modelo navegue simultaneamente por múltiplas dimensões da tabela. Se a estrutura estiver corrompida no chunk, a resposta será incorreta ou o modelo admitirá incapacidade — ambos os cenários são igualmente problemáticos para o atendente.

ESTRATÉGIA

Utilizar Azure Document Intelligence com o modelo de layout para extração estruturada das tabelas, preservando a relação linha-coluna em formato JSON ou Markdown serializado. Cada tabela deve ser tratada como unidade atômica de chunking — não fragmentada — com os cabeçalhos repetidos em todo chunk derivado. Para tabelas de frete, recomenda-se a criação de um índice secundário estruturado (tipo banco de dados tabelar em memória), consultado diretamente por uma ferramenta de SQL-over-data antes do RAG semântico.

SEÇÃO 1.2

1.2 PDFs Escaneados com OCR (SharePoint)

Desafio no pipeline. Documentos escaneados introduzem ruído tipográfico na base vetorial: caracteres mal reconhecidos ("l" confundido com "1", "rn" com "m") corrompem silenciosamente tokens críticos. Em manuais de segurança de carga, uma confusão entre "120kg" e "l20kg" pode gerar respostas incorretas sobre limites de peso. A qualidade do OCR é altamente dependente da resolução e do estado físico do documento original.

Impacto na qualidade. A degradação afeta tanto o embedding — vetores gerados a partir de texto com ruído ocupam posições imprecisas no espaço semântico — quanto a legibilidade da resposta final, que pode citar trechos com erros tipográficos, reduzindo a confiança do atendente no assistente.

ESTRATÉGIA

Aplicar pipeline de OCR com pós-processamento em dois estágios: (1) Azure AI Vision com OCR de alta resolução como extrator primário; (2) um modelo de linguagem menor (GPT-4o-mini ou equivalente) como pós-processador para correção de erros contextuais antes da indexação (técnica de OCR cleaning LLM). Documentos com confiança de OCR abaixo de 85% devem ser sinalizados para revisão humana e excluídos temporariamente da base ativa.

SEÇÃO 1.3

1.3 Wiki Confluence com Links Internos e Macros

Desafio no pipeline. A wiki do Confluence apresenta dois problemas estruturalmente distintos. O primeiro é a dependência contextual entre páginas via links internos: uma página sobre "Procedimento de Devolução" pode apenas referenciar outra sobre "Política de SLA", sem reproduzir o conteúdo. Se ambas forem indexadas como chunks isolados, o retrieval pode retornar a primeira sem a segunda, gerando uma resposta incompleta. O

segundo problema são as macros customizadas, que renderizam conteúdo dinâmico que a exportação via API retorna como placeholder XML sem conteúdo legível.

Impacto na qualidade. Perguntas que cruzam múltiplas páginas da wiki — frequentes em processos de compliance, que referenciam hierarquias de políticas — retornarão respostas parciais sem que o modelo perceba a incompletude.

ESTRATÉGIA

Utilizar a API REST do Confluence com o parâmetro `expand=body.storage` para obter o HTML completo e pré-processar os links internos em tempo de ingestão: cada link para outra página deve ser resolvido e o conteúdo-alvo incluído como contexto de vizinhança no chunk (link expansion limitada a um grau de profundidade). Macros não renderizáveis devem ser substituídas por placeholders descritivos e o link para a página Confluence incluído nos metadados do chunk.

SEÇÃO 1.4

1.4 Planilhas com Fórmulas Interdependentes

Desafio no pipeline. Planilhas de cálculo de frete contêm o valor final do cálculo apenas como resultado de uma cadeia de fórmulas que referencia outras abas, tabelas de parâmetros e células nomeadas. A extração bruta retorna os resultados calculados — se o arquivo foi salvo com os valores — ou strings de fórmula como `=VLOOKUP(A2,$Tabela_Zonas.$A:$D,3,0)`, completamente ininteligíveis para o modelo. O problema se agrava com planilhas atualizadas mensalmente: uma regra de negócio pode mudar em uma célula de parâmetro sem que haja versionamento explícito.

Impacto na qualidade. Uma pergunta sobre o valor de frete para determinada categoria retornará o resultado numérico sem a lógica subjacente, impedindo que o atendente explique ao cliente por que o valor é aquele. Alterações mensais nos parâmetros podem fazer a base retornar valores desatualizados se o re-indexing não ocorrer imediatamente após a atualização.

ESTRATÉGIA

Adotar desnormalização controlada em três passos: (1) executar as planilhas com `xlwings` para forçar o recálculo e extrair os valores computados; (2) gerar, via LLM ou script de parsing, um documento textual narrativo que descreve as regras de negócio embutidas nas fórmulas; (3) indexar o documento narrativo, não a planilha bruta. O arquivo original deve ser preservado e linkado nos metadados para auditoria.

2. Estimativa do Tamanho da Base em Tokens

A estimativa abaixo aplica a conversão padrão de **0,75 palavras por token** (equivalente a aproximadamente 1,33 tokens por palavra), regra prática amplamente utilizada para modelos da família GPT.

Fonte	Volume	Estimativa de palavras	Tokens (÷ 0,75)
PDFs SharePoint	800 docs × 10 págs × 300 palavras/pág	2.400.000 palavras	~3,2M tokens
Wiki Confluence	400 páginas × 1.500 palavras/pág	600.000 palavras	~800K tokens
Planilhas (desnorm.)	50 planilhas × ~2.000 palavras equiv.	100.000 palavras	~133K tokens
TOTAL ESTIMADO	—	~3.100.000 palavras	~4,1M tokens

CONCLUSÃO-CHAVE

A base total estimada em ~4,1 milhões de tokens é aproximadamente 32 vezes maior do que a janela de contexto do GPT-4o (128K tokens). Isso confirma que uma abordagem de 'stuffing' — inserir toda a documentação no prompt — é tecnicamente inviável e reforça de forma definitiva a necessidade de uma arquitetura RAG com retrieval seletivo de alta precisão.

3. Análise do Orçamento de Contexto

3.1 Decomposição da Janela de 128K Tokens

Com base nas características do cenário NovaTech, a distribuição recomendada da janela de contexto por query é a seguinte:

Componente	Tokens alocados	Justificativa
System prompt + instruções	~2.000	Persona do assistente, regras de citação, formato de resposta
Histórico de conversa (últimas 3 trocas)	~1.500	Contexto conversacional mínimo para follow-up
Query do usuário	~200	Pergunta típica de atendimento ao cliente
Chunks recuperados (contexto documental)	~120.000	Janela principal disponível para RAG
Buffer de geração (output tokens)	~4.300	Resposta com citações e estrutura
TOTAL	~128.000	Janela completa do GPT-4o

3.2 Capacidade de Chunks por Query

Com ~120.000 tokens disponíveis para contexto documental e chunks de 500 tokens cada:

Capacidade teórica: $120.000 \div 500 = 240$ chunks por query

Entretanto, inserir 240 chunks no contexto seria contraproducente por dois motivos. Primeiro, o efeito *lost in the middle* degrada a qualidade da resposta com contextos muito longos. Segundo, chunks de baixa relevância introduzem ruído e aumentam a probabilidade de alucinação por conflito de informações.

RECOMENDAÇÃO OPERACIONAL

Recuperar entre 8 e 15 chunks por query após o estágio de re-ranking. Isso consome entre 4.000 e 7.500 tokens de contexto documental — apenas 3 a 6% da janela disponível — mantendo o modelo focado em informação de alta relevância e eliminando o risco de *lost in the middle*.

3.3 Impacto na Estratégia de Chunking e Retrieval

A capacidade ampla da janela não deve ser interpretada como permissão para chunks maiores ou retrieval mais amplo. A decisão de manter chunks em 500 tokens com overlap de ~50 tokens é motivada por três fatores:

Granularidade de recuperação	de	Chunks menores permitem que o retrieval seja mais preciso — um chunk de 500 tokens cobre aproximadamente 2 a 3 parágrafos densos de manual operacional, suficiente para responder a maioria das perguntas pontuais sem incluir informação irrelevante.
Densidade de sinal semântico		Embeddings de texto gerados para chunks maiores que ~800 tokens tendem a ter vetores diluídos. Chunks de 300 a 600 tokens produzem embeddings mais discriminativos.

**Flexibilidade
composição**

de

Com chunks pequenos, o sistema pode recuperar 2 chunks de seções distintas de um mesmo documento para responder a uma pergunta composta, sem precisar carregar o documento inteiro.

4. Estratégia de Chunking e o Efeito Lost in the Middle

4.1 O Problema do Lost in the Middle

Pesquisas empíricas sobre LLMs demonstram consistentemente que a atenção do modelo não é uniforme ao longo do contexto: informações posicionadas no início e no final do contexto recebem peso significativamente maior do que aquelas no meio. Em um contexto com 15 chunks, o chunk na posição 8 pode ser praticamente ignorado pelo modelo, mesmo que seja o mais relevante para a resposta.

RISCO PARA A NOVATECH

Se a regra de cálculo de frete correta estiver no chunk 7 de 14, mas o chunk 1 contiver uma versão desatualizada da mesma regra, o modelo tenderá a usar a versão do início do contexto — produzindo uma resposta incorreta com aparência de confiança. Este risco é amplificado pelo fato de que a NovaTech possui documentos contraditórios entre versões.

4.2 Estratégia de Chunking Recomendada

Abordagem: Chunking semântico hierárquico com posicionamento prioritário.

P1

Chunking por unidade lógica

O tamanho de ~500 tokens deve ser um limite máximo, não um alvo fixo. A quebra deve ocorrer em fronteiras semânticas naturais: fim de seção, fim de parágrafo, fim de item de lista numerada. Uma seção com 350 tokens não deve ser concatenada com a seção seguinte apenas para 'completar' o chunk.

P2

Overlap contextual de ~50 tokens

Cada chunk deve incluir os últimos 50 tokens do chunk anterior como prefixo. Isso preserva continuidade narrativa para perguntas que exigem contexto de múltiplos parágrafos consecutivos.

P3

Metadados obrigatórios por chunk

Nome do documento, seção/título pai, número de página, data de última atualização, área responsável (Operações, Compliance ou Comercial) e hash de versão. Esses metadados permitem filtros de retrieval pré-semântico.

P4

Posicionamento estratégico no prompt

Dado o efeito lost in the middle, o sistema deve sempre inserir o chunk mais relevante (maior score após re-ranking) na primeira ou última posição do contexto documental, nunca no meio. Chunks de suporte devem ser inseridos após o chunk principal.

P5

Chunks especiais para tabelas

Tabelas de frete, SLAs e planilhas desnormalizadas devem ser armazenadas como chunks atômicos com um prefixo textual descritivo explícito. O prefixo garante que o embedding capture a intenção da tabela, e não apenas seus valores numéricos.

P6

Deteção e flag de conflito entre versões

Quando a similaridade coseno superar 0,85 entre chunks de diferentes versões com conteúdo divergente, ambos devem receber metadado conflito=true e a resposta deve incluir aviso explícito ao atendente sobre a necessidade de confirmação com a área responsável.

4.3 Tipos de Perguntas e Chunking Adequado

Tipo de pergunta	Exemplo	Estratégia de chunk	Posição no contexto
Pontual e factual	"Qual o SLA para cliente Gold?"	1 chunk atômico de tabela	Primeira posição
Procedimental	"Quais os passos para registrar reclamação?"	2–4 chunks sequenciais da mesma seção	Ordem de aparição, mais relevante primeiro
Comparativa	"Diferença entre devolução varejo e atacado?"	2 chunks de seções distintas	Chunk mais relevante primeiro e último
Regulatória/compliance	"Procedimento X está em conformidade com norma Y?"	3–5 chunks com metadados Compliance	Norma primeiro, procedimento depois
Cálculo de frete	"Frete 300kg, Zona Norte, prazo 72h?"	1 chunk de tabela + 1 chunk de regras	Regras primeiro, tabela depois

5. Considerações Complementares e Informações Ausentes

■	Volume de tokens por planilha O cenário não especifica o volume médio de tokens por página das planilhas após desnormalização, o que torna a estimativa de 2.000 palavras-equivalentes por planilha uma aproximação conservadora. Planilhas de cálculo de frete com múltiplas abas podem gerar narrativas significativamente maiores.
■	Controle de acesso documental (ACL) Não foi fornecida informação sobre o nível de permissões de acesso: se diferentes atendentes tiverem acesso a subconjuntos distintos da documentação, o pipeline de retrieval precisará implementar filtragem por ACL integrada ao Azure Active Directory, o que adiciona complexidade ao escopo.
■	Política de retenção de versões A política de retenção de versões anteriores de documentos não está definida. Se versões antigas permanecerem indexadas, o risco de conflito de informação aumenta substancialmente e a estratégia de detecção de conflito torna-se ainda mais crítica.

Viabilidade dentro do prazo de 3 meses

O projeto é tecnicamente viável dentro do prazo proposto para um MVP funcional, desde que o escopo seja priorizado em ordem decrescente de impacto:

P1 — Alta prioridade	PDFs nativos do SharePoint com chunking semântico
P2 — Alta prioridade	Wiki Confluence com expansão de links
P3 — Média prioridade	Planilhas desnormalizadas
P4 — Menor prioridade	PDFs escaneados com OCR (maior risco técnico)

NOTA FINAL	A integração ao Microsoft Teams via bot é nativa ao ecossistema M365 E3 e não representa risco técnico relevante. O principal risco de prazo reside na qualidade da documentação existente — documentos com OCR de baixa qualidade ou tabelas de frete muito complexas podem demandar mais tempo de pré-processamento do que o estimado. Recomenda-se iniciar o discovery com uma amostra representativa de 50 documentos para calibrar o esforço real de ingestão.
-------------------	---