

Sumário

1.	Contexto e Metodologia da Revisão	3
2.	Painel de Riscos — Visão Consolidada	3
3.	Pontos Fracos e Estimativas Otimistas Demais	4
3.		
1	Prazo de 3 Meses: Compressão Irreal do Discovery	4
3.		
2	Estimativa de Tokens: Subestimação Sistemática	5
3.		
3	OCR Cleaning LLM: Custo e Latência Ignorados	5
3.		
4	Threshold de Conflito (0,85 coseno): Sem Fundamento Empírico	6
3.		
5	Desnormalização de Planilhas: Dependência de Domínio Não Resolvida	6
3.		
6	Busca Híbrida: Complexidade de Tuning Subestimada	7
4.	Riscos Não Endereçados no Documento Original	7
4.		
1	Governança e Processo de Atualização Documental	7
4.		
2	Alucinação Factual Confiante — O Risco Mais Crítico	8
4.		
3	Latência de Resposta e Experiência do Atendente	9
4.		
4	Custos Operacionais Recorrentes (Azure AI)	9
4.		1
5	Adoção e Resistência Organizacional	0
4.		1
6	Ausência de Estratégia de Fallback e Escalada	0
4.		1
7	Multilingualidade e Dialeto Regionais	1
5.	Recomendações Corretivas Prioritárias	11
6.	Conclusão da Revisão Crítica	12

1. Contexto e Metodologia da Revisão

Este documento constitui uma revisão crítica independente da *Análise Técnica de Viabilidade — Assistente de IA Documental NovaTech*. O objetivo não é refutar as soluções propostas — que são tecnicamente corretas em seu nível de abstração — mas identificar lacunas que podem comprometer o projeto em produção: estimativas comprimidas, riscos não modelados, dependências implícitas e premissas otimistas que precisam ser explicitadas e mitigadas antes do início do desenvolvimento.

METODOLOGIA	A revisão foi conduzida sobre o documento original estruturado em 5 seções. Cada ponto crítico foi classificado por categoria (ponto fraco, estimativa otimista ou risco não endereçado) e por severidade (CRÍTICO, ALTO, MÉDIO), com recomendações corretivas objetivas.
--------------------	---

2. Painel de Riscos — Visão Consolidada

3	4	4	7
Riscos CRÍTICOS	Riscos ALTOS	Riscos MÉDIOS	Pontos não endereçados

ID	Tópico	Categoria	Severidade
R01	Prazo de 3 meses — compressão irreal do discovery	Estimativa otimista	CRÍTICO
R02	Alucinação factual confiante — risco operacional central	Risco não endereçado	CRÍTICO
R03	Governança documental ausente — base contamina-se mensalmente	Risco não endereçado	CRÍTICO
R04	Estimativa de tokens sistematicamente subestimada	Estimativa otimista	ALTO
R05	OCR cleaning LLM — custo e latência operacional ignorados	Ponto fraco	ALTO
R06	Latência de resposta RAG — impacto na UX do atendente	Risco não endereçado	ALTO
R07	Custos Azure AI — sem modelagem financeira no documento	Risco não endereçado	ALTO
R08	Threshold coseno 0,85 — sem validação empírica	Ponto fraco	MÉDIO
R09	Desnormalização de planilhas — dependência de domínio	Ponto fraco	MÉDIO
R10	Busca híbrida — tuning de pesos BM25/semântico ignorado	Ponto fraco	MÉDIO
R11	Adoção e resistência organizacional — não modelada	Risco não endereçado	MÉDIO
R12	Ausência de fallback e escalada para agente humano	Risco não endereçado	MÉDIO
R13	Multilingualidade e dialetos regionais — não avaliada	Risco não endereçado	BAIXO

3. Pontos Fracos e Estimativas Otimistas Demais

3.1 Prazo de 3 Meses: Compressão Irreal do Discovery

CRÍTICO — R01 Prazo de 3 meses para discovery + desenvolvimento + go-live

O documento original afirma que o projeto é 'tecnicamente viável dentro do prazo proposto para um MVP funcional'. Esta afirmação merece escrutínio rigoroso.

O prazo de 3 meses comprime atividades que, em projetos RAG corporativos de complexidade comparável, tipicamente consomem de 4 a 6 meses. A análise original ignora que o discovery sozinho — auditoria das 800+ fontes, levantamento de casos de uso com os 45 atendentes, definição de critérios de qualidade de resposta e alinhamento com as áreas responsáveis pela documentação — consome de 3 a 5 semanas em organizações com documentação não padronizada.

Atividade	Estimativa realista	O que o doc. original diz
Auditoria e catalogação das fontes	2–3 semanas	Implicitamente incluso no discovery
Pipeline de ingestão (OCR + tabelas + wiki)	3–4 semanas	Sugerido como P1–P4 sem prazo
Tuning de chunking e retrieval (iterativo)	2–3 semanas	Não modelado como atividade
Avaliação de qualidade (RAG evals)	2–3 semanas	Não mencionado
Integração Teams + UAT com atendentes	2–3 semanas	Mencionado como 'sem risco'
Tratamento de documentos conflitantes	1–2 semanas	Delegado a flag automático
Total estimado realista	12–18 semanas	12 semanas (3 meses)

RECOMENDAÇÃO Replanejar o projeto em 4 fases: (1) Discovery e prova de conceito com 50 documentos — 4 semanas; (2) Pipeline de ingestão completo — 5 semanas; (3) Integração Teams e ajuste de qualidade — 4 semanas; (4) Piloto com grupo reduzido de atendentes e go-live — 3 semanas. Total: 16 semanas (4 meses).

3.2 Estimativa de Tokens: Subestimação Sistemática

ALTO — R04 Estimativa de ~4,1M tokens subestima a base real

A premissa de 300 palavras por página para PDFs corporativos é conservadora para o lado errado.

Manuais operacionais de logística, especialmente os que incluem procedimentos passo a passo, tabelas de referência e notas regulatórias, tipicamente apresentam de 400 a 600 palavras por página. O documento original usa 300 palavras/página como base de cálculo para todos os PDFs — incluindo os documentos mais densos. Adicionalmente, a desnormalização narrativa das planilhas (estimada em 2.000 palavras por planilha) pode facilmente atingir 5.000 a 10.000 palavras para planilhas de frete com múltiplas abas e dezenas de regras de negócio interdependentes.

Fonte	Estimativa original	Estimativa revisada (p95)	Delta
PDFs SharePoint (800 docs)	~3,2M tokens	~5,3M a 8,5M tokens	+66% a +165%
Wiki Confluence (400 págs)	~800K tokens	~800K a 1,2M tokens	Em linha
Planilhas desnormalizadas (50)	~133K tokens	~500K a 1,0M tokens	+275% a +650%
TOTAL REVISADO	~4,1M tokens	~6,6M a 10,7M tokens	+60% a +160%

IMPACTO	O impacto não é na viabilidade do RAG — que continua necessário e viável — mas nos custos de embedding na ingestão inicial e no custo de re-indexing mensal. Uma base de 10M tokens re-indexada mensalmente com text-embedding-3-large gera custo recorrente que deve ser modelado no orçamento.
---------	--

3.3 OCR Cleaning LLM: Custo e Latência Ignorados

ALTO — R05	OCR cleaning via LLM não é gratuito nem instantâneo
O documento propõe usar GPT-4o-mini como pós-processador de OCR sem modelar o custo ou o tempo de execução desta etapa no pipeline de ingestão.	

O documento original descreve corretamente a técnica de OCR cleaning LLM, mas omite que esta abordagem tem implicações operacionais significativas. Processando os PDFs escaneados — estimados em uma fração dos 800 documentos, mas potencialmente dezenas de documentos com várias páginas — cada página precisa ser enviada ao modelo para correção. Isso transforma a ingestão de um processo de indexação em um processo de geração em lote, com custo proporcional ao volume de tokens processados e latência de horas para o corpus completo. Além disso, o LLM de limpeza pode *introduzir* erros ao 'corrigir' termos técnicos de logística que não fazem parte do vocabulário de treinamento do modelo (códigos de produto, nomenclaturas internas, siglas operacionais).

RECOMENDAÇÃO	Avaliar primeiro se a proporção de PDFs escaneados justifica o custo da limpeza via LLM. Para documentos com conteúdo técnico muito específico, considerar uma whitelist de termos que o LLM de limpeza não deve modificar. Priorizar a digitalização nativa dos documentos mais acessados antes de depender de OCR.
--------------	--

3.4 Threshold de Conflito (0,85 coseno): Sem Fundamento Empírico

MÉDIO — R08	O valor 0,85 de similaridade coseno para detecção de conflito foi apresentado sem calibração
Este threshold determinará quantos documentos serão sinalizados como conflitantes — e um valor incorreto gera dois problemas opostos igualmente graves.	

Um threshold de 0,85 é arbitrário sem validação no corpus específico da NovaTech. Se for alto demais (ex.: 0,90+), documentos genuinamente conflitantes passarão despercebidos. Se for baixo demais (ex.: 0,80-), documentos sobre o mesmo tema mas com regras distintas e corretas serão erroneamente flagados, sobrecarregando a equipe de revisão com falsos positivos e gerando desconfiança no sistema. O documento não descreve como o threshold será calibrado, quem o validará, ou com que frequência será revisado.

3.5 Desnormalização de Planilhas: Dependência de Domínio Não Resolvida

MÉDIO —
R09**A geração de narrativas textuais a partir de fórmulas exige especialista de domínio**

O documento propõe usar 'LLM ou script de parsing' para gerar a narrativa, sem reconhecer que esta é a etapa mais dependente de validação humana de todo o pipeline.

Um LLM que lê uma fórmula VLOOKUP e gera a narrativa 'o frete é calculado multiplicando o peso pela tarifa base' pode estar correto — ou pode estar omitindo uma condição de exceção crítica que está em uma aba auxiliar não mapeada. A narrativa gerada automaticamente precisa ser validada por um analista da área Comercial ou de Operações para cada planilha. Este processo de validação não está modelado no prazo nem nos recursos do projeto.

3.6 Busca Híbrida: Complexidade de Tuning Subestimada

MÉDIO —
R10**Busca híbrida (BM25 + semântica) requer calibração iterativa dos pesos**

O documento recomenda busca híbrida sem detalhar o processo de tuning dos pesos relativos entre BM25 (léxico) e busca semântica (vetorial).

O balanço entre BM25 e busca semântica no Azure AI Search é controlado pelo parâmetro alpha (0 = puramente BM25, 1 = puramente semântico). Para perguntas sobre códigos de produto e siglas operacionais específicas da NovaTech, BM25 tende a ter melhor precisão. Para perguntas em linguagem natural sobre conceitos de procedimento, a busca semântica é superior. O valor ótimo de alpha para o corpus da NovaTech só pode ser determinado empiricamente, com um conjunto de perguntas de avaliação curado pelos próprios atendentes — atividade que o documento não inclui no escopo.

4. Riscos Não Endereçados no Documento Original

4.1 Governança e Processo de Atualização Documental

CRÍTICO —
R03

A ausência de processo unificado de revisão documental é o risco estrutural mais severo do projeto

O documento original menciona brevemente que 'alguns documentos se contradizem entre versões' e que 'a equipe resolve perguntando para quem sabe'. Este é o problema central — e não foi adequadamente endereçado.

O assistente RAG será tão confiável quanto a documentação que indexa. Se a NovaTech não resolver o processo de governança documental antes ou em paralelo ao desenvolvimento do assistente, o sistema irá **automatizar a distribuição de informação inconsistente em escala**. Hoje, um atendente experiente filtra mentalmente as contradições ao 'perguntar para quem sabe'. O RAG não tem esse filtro — ele apresentará a contradição ao atendente como se fosse informação autorizada, possivelmente com confiança aparente.

!

Versionamento inexistente: Documentos não têm versão formal. O campo 'data de última atualização' nos metadados do chunk não tem significado confiável se o autor não atualizar o documento ao revisar o conteúdo.

!

3 áreas sem processo unificado: Operações, Compliance e Comercial atualizam documentos de forma independente. Uma mudança de SLA no Comercial pode não ser refletida no manual de procedimentos de Operações por semanas.

!

Nenhuma menção a document owner: O documento não propõe designar responsáveis por área para validação periódica da base indexada — o que é pré-requisito para qualquer RAG corporativo confiável.

RECOMENDAÇÃO

Incluir no escopo do projeto — como pré-requisito para o go-live — a definição de: (1) um processo de versionamento mínimo para os documentos de maior impacto operacional; (2) um document owner por área com responsabilidade formal de validar o conteúdo indexado trimestralmente; (3) um pipeline de detecção de documentos desatualizados baseado em data de modificação no SharePoint/Confluence. Sem isso, o assistente degradará em qualidade ao longo do tempo.

4.2 Alucinação Factual Confiante — O Risco Mais Crítico

CRÍTICO —
R02

O documento original não trata do risco de alucinação em respostas sobre dados operacionais críticos

Em logística, uma resposta incorreta sobre prazo de SLA, valor de frete ou procedimento de devolução tem consequência direta: o cliente toma uma decisão baseada em informação errada.

Sistemas RAG com GPT-4o reduzem alucinações, mas não as eliminam. O risco específico para a NovaTech é a **alucinação factual confiante**: o modelo não diz 'não sei' — ele apresenta um valor de frete plausível (mas incorreto) ou um prazo de SLA que mistura informações de duas fontes contraditórias, com a mesma formatação e tom de uma resposta correta. O atendente, sob pressão de 320 chamados/dia, não tem tempo para verificar cada resposta na fonte original.

O documento menciona citação de fonte nos metadados, mas não define: (a) o formato exato da citação ao atendente; (b) um mecanismo de confidence score visível na interface; (c) uma política de quando o assistente deve se recusar a responder por insuficiência de evidência; (d) um processo de feedback para rastrear respostas incorretas que chegaram ao cliente.

RECOMENDAÇÃO	Implementar obrigatoriamente: (1) exibição do trecho-fonte ao lado de cada resposta — não apenas o nome do documento, mas o parágrafo exato; (2) um score de confiança calculado a partir do similarity score do chunk mais relevante, exibido visualmente (ex.: baixo/médio/alto); (3) uma política de 'recusa informada' — quando nenhum chunk atinge score mínimo, o assistente responde 'Não encontrei informação suficiente — consulte [documento X] ou acione o supervisor'; (4) um botão de feedback (correto/incorreto) na interface do atendente para alimentar um ciclo de melhoria contínua.
--------------	---

4.3 Latência de Resposta e Experiência do Atendente

ALTO — R06

O pipeline RAG completo tem latência que pode frustrar o objetivo de reduzir o tempo de busca

O objetivo é reduzir o tempo de busca de 12 para menos de 2 minutos. O documento não modela a latência do pipeline RAG.

Etapas do pipeline	Latência típica	Observação
Embedding da query	~100–200ms	Azure OpenAI — bem documentado
Busca vetorial (Azure AI Search)	~100–300ms	Depende do tamanho do índice
Re-ranking (cross-encoder)	~300–800ms	Frequentemente omitido em estimativas
Chamada ao GPT-4o (geração)	~2.000–8.000ms	Varia com tamanho do contexto
TOTAL estimado por query	~2,5s a 9,3s	Sem streaming de tokens
Com streaming de tokens	~1,5s até primeiro token	Melhor experiência percebida

RECOMENDAÇÃO	Implementar streaming de tokens na interface Teams (o primeiro token aparece em ~1,5s, melhorando drasticamente a percepção de velocidade). Definir um SLA interno de P95 < 5s para a resposta completa e monitorar ativamente. Se o re-ranker introduzir latência inaceitável, avaliar sua remoção e compensar com retrieval mais seletivo.
--------------	--

4.4 Custos Operacionais Recorrentes (Azure AI)

ALTO — R07

O documento original não inclui nenhuma modelagem de custos operacionais recorrentes

A NovaTech tem 320 chamados/dia, ~60% com consulta documental = 192 queries/dia ao RAG.

Item de custo	Volume mensal est.	Custo estimado/mês
Queries ao GPT-4o (192/dia x 22 dias úteis)	~4.224 queries x 8K tokens avg.	~USD 200–350
Re-indexing mensal (base ~7M tokens)	1x/mês, embedding-3-large	~USD 20–30
Azure AI Search (índice vetorial)	Camada S1 mínima recomendada	~USD 250/mês
Azure Document Intelligence (OCR)	Ingestão inicial + incremental	~USD 50–100
TOTAL ESTIMADO MENSAL	—	~USD 520–730/mês
TOTAL ESTIMADO ANUAL	—	~USD 6.240–8.760/ano

NOTA

Estas estimativas são orientativas e variam com o modelo de precificação do Azure contratado pela NovaTech. Devem ser validadas com a área de TI antes da aprovação do orçamento do projeto. O custo incremental é justificável pelo ROI estimado (192 queries x 10min de economia/query = ~32 horas/dia de atendimento recuperadas), mas precisa ser apresentado explicitamente à diretoria.

4.5 Adoção e Resistência Organizacional

**MÉDIO —
R11**

O fator humano de adoção não foi modelado — e é frequentemente o principal motivo de fracasso

O documento não menciona estratégia de change management, treinamento dos 45 atendentes ou gestão de expectativas.

Atendentes que hoje 'perguntam para quem sabe' desenvolveram uma rede de conhecimento tácito que o RAG não replicará imediatamente. A resistência pode se manifestar de formas silenciosas: atendentes que ignoram a sugestão do assistente e continuam perguntando para colegas, ou que interpretam uma resposta incorreta do sistema como evidência de que 'a ferramenta não funciona' e param de usá-la. Sem um programa estruturado de adoção, o ROI projetado não se materializa.

4.6 Ausência de Estratégia de Fallback e Escalada

**MÉDIO —
R12**

O documento não define o que acontece quando o assistente não sabe responder

Um assistente sem comportamento de fallback bem definido gera experiências frustrantes que destroem a confiança do usuário na ferramenta.

Cenários não cobertos incluem: perguntas sobre exceções não documentadas (frequentes em logística); perguntas sobre procedimentos em fase de transição, quando a documentação nova ainda não está publicada; perguntas sobre clientes ou contratos específicos que não estão na documentação geral. Para cada um desses casos, o assistente precisa de um comportamento explícito — não apenas retornar o chunk menos relevante com aparência de resposta.

RECOMENDAÇÃO

Definir três respostas-padrão de fallback: (1) 'Informação não encontrada na base — consulte o supervisor de turno'; (2) 'Encontrei informações possivelmente conflitantes — recomendo verificar com a área [X]'; (3) 'Este tipo de exceção não está coberto pela documentação padrão — acione o time de [área]'. O fallback correto é tão importante quanto a resposta correta.

4.7 Multilingualidade e Dialectos Regionais

**BAIXO —
R13**

Não avaliado: linguagem coloquial dos atendentes vs. linguagem formal dos documentos

Atendentes fazem perguntas em linguagem natural informal; os documentos usam linguagem técnica formal. Este gap semântico pode reduzir a precisão do retrieval.

Um atendente que pergunta 'quanto tá o frete pra interior de SP pra carga pesada?' usa vocabulário diferente de 'tarifa de frete para carga acima de 500kg com destino a municípios do interior do estado de São Paulo'. O embedding do GPT-4o é robusto o suficiente para lidar com parte dessa variação, mas consultas muito coloquiais ou com regionalismos podem reduzir a qualidade do retrieval. Isso deve ser validado empiricamente na fase de testes com os atendentes reais.

5. Recomendações Corretivas Prioritárias

CRÍTICO	Resolver a governança documental antes do go-live Designar document owners por área, implementar versionamento mínimo e definir SLA de atualização da base indexada. Este é o pré-requisito que o documento original omite e que determina a confiabilidade do sistema em produção.
CRÍTICO	Implementar mecanismo de confidence score e fallback explícito O atendente precisa saber, a cada resposta, o nível de confiança do sistema e o que fazer quando a confiança é baixa. Exibir o trecho-fonte, o score de relevância e opções de escalada diretamente na interface Teams.
CRÍTICO	Replanejar o prazo para 16 semanas (4 meses) Incluir atividades de RAG evals, tuning iterativo de chunking/retrieval, validação humana das narrativas de planilhas e programa de adoção com os atendentes.
ALTO	Modelar os custos operacionais recorrentes Apresentar à diretoria uma estimativa de TCO (Total Cost of Ownership) incluindo custos Azure AI recorrentes e compará-los com o ROI estimado de redução do tempo de atendimento.
ALTO	Implementar streaming de tokens na interface Teams Reduz drasticamente a latência percebida pelo atendente e é tecnicamente simples com a API do GPT-4o. Definir SLA interno de P95 < 5s para resposta completa.
MÉDIO	Calibrar empiricamente o threshold de detecção de conflito Construir um conjunto de teste com documentos sabidamente conflitantes e não-conflitantes para validar o threshold antes de aplicá-lo em produção.
MÉDIO	Incluir programa de change management no escopo Treinar os 45 atendentes, definir métricas de adoção e realizar sessões de feedback nas primeiras semanas de operação. Sem adoção, o ROI não se materializa.

6. Conclusão da Revisão Crítica

O documento original de Análise Técnica de Viabilidade apresenta uma arquitetura RAG tecnicamente sólida e um nível de detalhe adequado para as decisões de pipeline de ingestão, estratégia de chunking e gerenciamento de contexto. As recomendações sobre Azure Document Intelligence, busca híbrida, posicionamento de chunks e desnormalização de planilhas são tecnicamente corretas e representam boas práticas da área.

Entretanto, esta revisão crítica identifica que o documento opera em um nível de abstração que omite os riscos mais relevantes para o **sucesso do projeto em produção**. Os três riscos críticos — prazo irrealista, ausência de governança documental e risco de alucinação confiante — não são riscos técnicos do pipeline RAG. São riscos **organizacionais e de produto** que a análise original não tinha como escopo endereçar, mas que precisam ser tratados para que a solução técnica correta gere o impacto esperado.

VEREDICTO DA REVISÃO

A arquitetura proposta é viável e recomendada com as ressalvas desta revisão. O projeto deve ser aprovado com as seguintes condicionantes: (1) replanejamento do prazo para 16 semanas; (2) inclusão da governança documental como workstream paralelo; (3) definição do mecanismo de confidence score e fallback antes do início do desenvolvimento da interface; (4) apresentação de modelagem de custos recorrentes à diretoria antes da aprovação final do orçamento.

Revisão crítica elaborada em 09 de June de 2026. Este documento deve ser lido em conjunto com a Análise Técnica de Viabilidade original.